

Прогнозирование цен бриллиантов

1 Введение

Задача точного прогнозирования цены бриллиантов имеет высокую практическую значимость в ювелирном деле, страховании, аудите закупочных цен и контроле розничных сетей. Автоматизированная оценка позволяет минимизировать субъективный фактор эксперта, выявлять недооценённые или переоценённые камни, а также формировать прозрачную ценовую политику. В данной работе строится регрессионная модель, предсказывающая стоимость бриллианта в долларах США по его физическим и качественным характеристикам.

Датасет Diamonds взят из открытого источника Kaggle и содержит 53 940 записей с 10 признаками. Целевой переменной выступает price (цена в долларах). Числовые признаки включают вес в каратах (carat), процентную глубину (depth), ширину верхней площадки (table), а также размеры в миллиметрах: длину (x), ширину (y) и глубину (z). Категориальные переменные описывают качество огранки (cut: Fair, Good, Very Good, Premium, Ideal), цвет (color: от J – худший, до D – лучший) и чистоту (clarity: от I1 – наихудшая, до IF – наилучшая). Такой набор предикторов охватывает основные ценообразующие факторы бриллиантов.

Практические сценарии применения прогнозной модели охватывают оперативную предварительную оценку бриллиантов в ювелирных салонах, автоматическую верификацию закупочных цен для крупных сетей, расчет страховой стоимости изделий и мониторинг рыночной конъюнктуры. Высокая точность модели критически важна в премиальном сегменте, где даже небольшая относительная ошибка выражается в значительной абсолютной сумме.

2 Методология

Для решения задачи использован стек инструментов, объединяющий автоматизированное построение моделей и интерпретируемое машинное обучение. Подбор оптимальной модели выполнен с помощью библиотеки

AutoGluon в режиме `medium_quality` с ограничением по времени 7200 секунд. В качестве базового уровня реализована линейная регрессия со стандартизацией числовых переменных и one-hot кодированием категорий. Интерпретация результатов проведена методом SHAP (SHapley Additive exPlanations) на основе одной из наиболее точных моделей ансамбля – LightGBM.

Такая комбинация позволяет получить одновременно высокоточную и объяснимую систему. AutoGluon автоматически сравнивает множество алгоритмов и формирует взвешенный ансамбль, не требуя ручного подбора гиперпараметров. SHAP-анализ даёт возможность понять вклад каждого признака как на глобальном уровне, так и для отдельных наблюдений, что необходимо для доверия к модели со стороны экспертов-геммологов и принятия обоснованных бизнес-решений.

3 Предварительный анализ данных

Пропущенные значения в датасете отсутствуют, что упрощает подготовку данных. Распределение цены имеет выраженную правостороннюю асимметрию: среднее значение составляет около 3945, медиана — 2410, минимальная цена — 326, максимальная — 18823. Коэффициент корреляции Пирсона между ценой и весом (carat) равен 0.92, что указывает на доминирующую роль массы камня в формировании стоимости.

Средние цены в разрезе категорий качества демонстрируют неочевидные закономерности. В таблице 1 приведены средние значения `price` по уровням огранки, цвета и чистоты.

Таблица 1. Средняя цена бриллианта в зависимости от категориальных признаков

Признак	Категория	Средняя цена, \$
cut	Fair	4 330
	Good	3 961

Признак	Категория	Средняя цена, \$
	Very Good	3 987
	Premium	4 607
	Ideal	3 463
color	J	5 343
	I	5 105
	H	4 498
	G	4 004
	F	3 740
	E	3 085
	D	3 179
clarity	I1	3 941
	SI2	5 094
	SI1	4 000
	VS2	3 937
	VS1	3 839
	VVS2	3 277
	VVS1	2 543
	IF	2 903

На первый взгляд парадоксально, что бриллианты с лучшей огранкой (Ideal) и высшими характеристиками цвета (D, E) и чистоты (IF, VVS1) имеют сравнительно невысокую среднюю цену. Это объясняется тем, что камни исключительного качества чаще встречаются в мелких размерных группах,

тогда как крупные бриллианты нередко обладают худшими значениями цвета и чистоты, но имеют подавляюще высокую цену за счёт веса. Таким образом, вес выступает основным драйвером цены, а качественные признаки влияют нелинейно и требуют многомерного моделирования.

4 Моделирование

AutoGluon в ходе автоматического поиска обучил девять моделей: LightGBMXT, LightGBM, RandomForestMSE, CatBoost, ExtraTreesMSE, NeuralNetFastAI, XGBoost, NeuralNetTorch и LightGBMLarge. Лучшей признан ансамбль WeightedEnsemble_L2, агрегирующий предсказания шести алгоритмов. Состав ансамбля и веса моделей приведены в таблице 2.

Таблица 2. Состав ансамбля WeightedEnsemble_L2

Модель	Вес
ExtraTreesMSE	0.385
LightGBM	0.154
CatBoost	0.154
NeuralNetFastAI	0.154
RandomForestMSE	0.077
XGBoost	0.077

На отложенной тестовой выборке (20 % данных) ансамбль продемонстрировал $RMSE = 492.72$ и коэффициент детерминации $R^2 = 0.9843$. Базовая линейная регрессия при тех же условиях показала $RMSE = 1089.38$ и $R^2 = 0.9232$. Автоматически построенная модель снизила ошибку более чем в два раза, что имеет прямое финансовое выражение. Для бриллианта стоимостью 15 000 ошибка линейной модели в среднем составляет порядка 1089, тогда как ансамбль ошибается примерно на 493 \$. В задачах страховой

оценки и контроля закупочных цен премиального сегмента такое улучшение точности является критичным.

5 Интерпретация модели (SHAP)

Для детального понимания логики модели применён SHAP-анализ на базе LightGBM ($RMSE = 518.17$ \$, $R^2 = 0.9826$), одной из составляющих ансамбля. Глобальная важность признаков, выраженная в среднем абсолютном значении SHAP в долларах, представлена в таблице 3.

Таблица 3. Глобальная важность признаков

Признак	Средний SHAP, \$
carat	2073
y	941
clarity	618
color	391
z	170
x	146
cut	68
depth	39
table	21

Вес carat ожидаемо лидирует с большим отрывом. Размерный признак y (ширина) оказался вторым по значимости, что может отражать предпочтения рынка к визуальному размеру бриллианта при фиксированной массе. Качественные характеристики clarity и color вносят заметный, но существенно меньший вклад, а огранка (cut) и пропорции (depth, table) оказывают наименьшее влияние на прогноз.

Средние SHAP-значения для категорий демонстрируют экономически логичную направленность. Для цвета значения возрастают от -1158 для наихудшего J до $+568$ для наилучшего D. Чистота показывает ещё больший диапазон: от -2327 у I1 до $+1533$ у IF. Таким образом, модель корректно усвоила иерархию качества, заложенную в геммологической системе оценки.

SHAP позволяет выявлять аномалии в данных. Например, для наблюдения №0 (каратность 2.14, цвет D, чистота SI2) фактическая цена составила 931, тогда как прогноз модели достиг 15658. Разложение SHAP показало, что главный положительный вклад внесли carat ($+7\,220$), y ($+5482$), и цвет D ($+1\,199$), а отрицательный — x (-1418) и clarity SI2 (-781 \$). Подобное расхождение между фактом и предсказанием сигнализирует о возможной ошибке в данных либо о неучтённом дефекте камня. Возможность оперативно находить такие записи делает интерпретируемую модель ценным инструментом контроля качества информации и аудита цен.

Практическая польза SHAP-объяснений заключается в формировании доверия к автоматическим оценкам. Ювелир-оценщик или страховой агент может не только получить прогноз, но и увидеть, какие именно характеристики и в каком направлении повлияли на итоговую стоимость, что приближает «чёрный ящик» к привычной логике экспертной оценки.

6 Обсуждение и выводы

Построенная модель демонстрирует высокое качество: $R^2 = 0.9843$ означает, что 98.4 % вариации цены объяснено признаками. Главным драйвером стоимости является вес бриллианта, тогда как характеристики цвета и чистоты выступают второстепенными корректирующими факторами. Ансамбль `WeightedEnsemble_L2` уверенно превосходит линейный базовый уровень и пригоден для практического использования.

Вместе с тем следует учитывать ограничения. В датасете присутствуют статистические выбросы: по carat около 3.5 % наблюдений, по price около 6.5 %. Они не удалялись, поскольку отражают реальные дорогостоящие камни, но могут влиять на поведение модели в крайних диапазонах цен. Кроме того, в

наборе данных отсутствуют такие значимые факторы, как флуоресценция, форма огранки, регион продажи и наличие сертификата, которые в реальной практике могут существенно корректировать стоимость. Рыночная конъюнктура и временные тренды также остались за рамками модели.

Рекомендуемые направления применения включают предварительную оценку в ювелирных магазинах для быстрого расчёта стоимости на основе паспортных характеристик, автоматическую проверку закупочных цен в системах управления товарными запасами, а также использование в страховых компаниях для оперативного расчёта страховой суммы. Для дальнейшего повышения точности и расширения области применимости целесообразно дополнить датасет сведениями о флуоресценции, типе и качестве полировки, а также географическом рынке продажи. Учёт временного фактора позволит адаптировать модель к динамике цен на алмазном рынке.

7 Заключение

Решена задача регрессионного прогнозирования цены бриллиантов на основе открытых данных. Применение AutoGluon позволило получить ансамблевую модель с $R^2 = 0.9843$ и снизить ошибку прогноза более чем вдвое по сравнению с линейной регрессией. SHAP-анализ подтвердил адекватность модели, выявил доминирующее влияние веса и корректное ранжирование качественных характеристик, а также продемонстрировал способность обнаруживать аномалии в данных. Проект иллюстрирует полный цикл анализа данных — от разведочного анализа и автоматического моделирования до интерпретируемых выводов, готовых к интеграции в бизнес-процессы ювелирной отрасли и страхования.